

시험성적에 관한 회귀분석

12241701 박준형 / 12214256 최진호

0. 요약

본 분석은 학생들의 학업 성취도에 영향을 미치는 다양한 요인을 탐색하고, 어떤 요인이 학생의 최종 시험 성적(Exam_Score)을 예측하는 데 중요한 역할을 하는지 보이는 것을 목적으로 한다. 이를 위해 학생 개인의 학습 습관, 심리적 상태, 가정 환경, 그리고 학교 환경과 관련된 여러 변수를 수집한 StudentPerformanceFactors.csv 데이터를 활용한다. 최종적으로 회귀분석 모델을 구축하여 각 요인의 상대적 영향력을 평가하고자 한다.

1. 데이터 소개

데이터 분석 및 기계학습 플랫폼 '캐글(Kaggle)'에 공개된 'Student Performance Factors' 데이터셋(StudentPerformanceFactors.csv)을 사용하였다. 본 데이터는 총 20개의 변수와 6607개의 관측치(학생)로 구성되어 있다. 이 변수들은 학생 개인의 학습 습관, 심리적 상태, 가정 환경, 그리고 학교 환경과 관련된 다양한 요인들을 포함하고 있으며, 전체 변수의 목록은 <표 1-1>과 같다.

<표 1-1. 전체 변수>

변수명	관측치 수
Hours_Studied	6607
Attendance	6607
Parental_Involvement	6607
Access_to_Resources	6607
Extracurricular_Activities	6607
Sleep_Hours	6607
Previous_Scores	6607
Motivation_Level	6607
Internet_Access	6607
Tutoring_Sessions	6607
Family_Income	6607
Teacher_Quality	6529
School_Type	6607
Peer_Influence	6607
Physical_Activity	6607

Learning_Disabilities	6607
Parental_Education_Level	6517
Distance_from_Home	6540
Gender	6607
Exam_Score	6607

2. CDA(확증적 데이터 분석)

본 데이터에 대해 이론적 기반을 마련하기 위해 기존의 연구, 논문을 통해 변수 간에 관계에 대해 분석하였다. 학생의 학업 성취도에 영향을 끼치는 요인에 대한 연구는 교육학, 사회학, 심리학 등 다양한 분야에서 활발히 이루어져 왔다. 이 연구들은 공통적으로 학생 개인의 노력뿐 아니라 가정 배경, 학교 환경 등 복합적인 요인이 작용함을 보여준다.

가장 일관되게 보고되는 요인은 가정의 사회경제적 지위이다. 장상수(2016)의 연구에 따르면, 부모의 학력, 직업, 가정의 소득 등으로 측정되는 사회경제적 지위는 학생의 학업 성취도와 강력한 상관관계를 보인다. 본 데이터의 Parental_Education_Level와Family_Income 변수는 이러한 사회경제적 지위를 대리하는 주요 변수로 볼 수 있으며, 이 변수들이 학생 성적에 긍정적인 영향을 미칠 것이라 가설을 세울 수 있다.

또한, 학생 개인의 학습 관련 행동 및 태도 역시 중요한 예측 변수이다. 학습 시간(Hours_Studied),

수업 참여도(Attendance), 학습 동기 (Motivation_Level) 등은 신문승(2018)의 연구에서도 학업 성취도를 설명하는 핵심 요인으로 강조된다. 특히 Previous_Scores (이전 성적)는 현재 성적을 예측하는 가장 강력한 변수 중 하나로 알려져 있으며, 이는 자기 효능감과도 연결된다(박영신, 김의철, 2003). 이러한 선행 연구들의 이론적 배경을 바탕으로, 제공된 19개의 예측 변수들이 학생의 Exam_Score에 어떠한 영향을 미치는지 분석하고자 한다.

3. EDA(탐색적 데이터 분석)

본격적인 분석에 앞서 본 데이터가 가진 고유한 특성과 패턴에 대해 시각화를 통해 알아본다.

가. 데이터 전처리

20개의 변수들 중 대부분이 6607개의 관측치를 모두 가지고 있다. 하지만 세 개의 변수 'Teacher_Quality', 'Parental_Education_Level', 'Distance_from_Home'의 경우 결측치가 존재한다. 세 변수의 결측치의 수는 전체의 각각 1.18%, 1.36%, 1.01%로 낮아 특정 값으로 대체한다고 하더라도 원래의 분포를 왜곡시키지 않을 확률이 매우 높다. 결측치가 존재하는 세 변수 모두 범주형 변수이므로 평균이나, 중앙값보다는 각 변수의 최빈값을 대체하는 값으로 하였다.

범주형 변수의 경우 One-hot encoding을 수행해 범주의 개수만큼 가변수를 생성하여 존재 유무를 0과 1로 표현하였다. High, Medium, Low로 범주가 구성되어 있는 경우, 변수명을 (변수명)_High처럼 하여 범주의 개수와 같은 가변수를 추가하고, 기존의 변수는 제거하여 다음과 같은 변수들로 구성하였다. 이때 기존의 동일한 변수로부터 생성된 가변수들은 다음과 같은 관계가 생긴다.

(변수명)_High + (변수명)_Medium + (변수명)_Low = 1 / (변수명_Yes + (변수명)_No = 1


세 변수 사이에 완벽한 선형관계가 생기게 되고 이 상태로 모형을 적합하면 다중공선성의 문제가

생길 수 밖에 없다. 생성된 가변수 중 하나를 제거하여 다중공선성의 문제를 방지하였다. 제거하는 변수는 다음과 같이 지정하였다. 범주의 수가 2개인 경우 임의로 한 가변수를 제거하였으며, 범주의 수가 3개인 경우 Medium, Neutral, Moderate 과 같이 중간 값의 가변수를 제거하였다. 이를 통해 제거된 Medium 범주가 향후 회귀계수 해석에서 기준 역할을 하게 된다. 이를 통해 최종적으로 선정된 변수들은 다음과 같다.

<표 3-1. 전처리 이후 전체 변수>

변수명	관측치 수
Hours_Studied	6607
Attendance	6607
Parental_Involvement_High	6607
Parental_Involvement_Low	6607
Access_to_Resources_High	6607
Access_to_Resources_Low	6607
Extracurricular_Activities_Yes	6607
Sleep_Hours	6607
Previous_Scores	6607
Motivation_Level_High	6607
Motivation_Level_Low	6607
Internet_Access_Yes	6607
Tutoring_Sessions	6607
Family_Income_High	6607
Family_Income_Low	6607
Teacher_Quality_High	6607
Teacher_Quality_Low	6607
School_Type_Private	6607
Peer_Influence_Positive	6607
Peer_Influence_Negative	6607
Physical_Activity	6607
Learing_Disabilities_Yes	6607
Parental_Education_Level_College	6607
Parental_Education_Level_Postgraduate	6607
Distance_from_Home_Near	6607
Distance_from_Home_Far	6607
Gender_Male	6607

나. 반응변수 분포




반응변수로 할 시험성적은 위와 같이 구성된다. 시험성적에 대한 분포를 보면 평균 약 67점을 기준으로 65-75점 사이에 데이터의 상당수가 몰려 있다. 또한 정규분포와 유사한 분포를 가졌으나 오른쪽으로 꼬리가 길게 나와 있어 평균보다 큰 값을 가지는 관측치들이 다수 존재함을 알 수 있다. 이는 회귀에서 표준가정이 위배되지 않는지 모형에 대하여 확인을 할 필요가 있어 보인다.

우측 통계량에서 최댓값이 101로 일반적인 시험 성적의 범위 0-100 사이를 넘어 101인 값이 존재한다. 100점을 초과하는 관측치를 확인해보니 1525번째 관측치 하나의 시험 성적만 101의 값을 가졌다. 이는 데이터의 입력 과정에서 생긴 오류, 혹은 기본 점수에서 추가로 받은 점수로 인해 100점을 초과한 값을 가진 것으로 보인다. 해당 관측치는 일반적인 시험 성적의 범위에 맞추기 위해 100점으로 조정하였다.

다. 예측변수 분포

예측 변수들이 반응변수인 Exam_Score와 어떤

한 관계를 갖는지 파악하기 위해, 변수의 형태에 따라 시각화를 진행하였다. 범주형 변수들은 박스플롯(Box Plot)을, 수치형 변수들은 산점도(Scatter Plot)를 사용하여 분포를 확인하였다.




박스플롯을 활용해 범주형 변수별 Exam_Score의 분포를 살펴본 결과, 몇 가지 뚜렷한 경향이 확인되었다. 우선, 긍정적 연관성을 보이는 변수들은 앞선 CDA 단계에서 도출한 결과와 일관된 패턴을 나타냈다. Parental_Involvement, Access_to_Resources, Motivation_Level, Family_Income, Teacher_Quality, Peer_Influence, Parental_Education_Level과 같은 변수들은 범주 수준이 Low/Negative에서 High/Positive로 이동할수록 Exam_Score의 중앙값이 꾸준히 상승했고, 전체 분포 또한 보다 높은 성취로 이동하는 경향

이 있었다. Distance_from_Home 역시 Near 범주가 Far 범주보다 더 높은 점수 분포를 보였다.

반면, Learning_Disabilities 변수는 명확한 부정적 관계를 보였는데, Yes 범주 학생들의 Exam_Score 중앙값이 No 범주 대비 크게 낮았다. 이는 학습상의 어려움이 성취도에 직접적인 제약 요인이 될 수 있음을 보여준다.

마지막으로, Extracurricular_Activities, Internet_Access, School_Type, Gender 등은 범주 간 중앙값이나 IQR의 차이가 미미해, Exam_Score 예측에 있어 상대적으로 영향력이 낮을 가능성이 있다.

<수치형 변수 산점도>



산점도를 활용해 수치형 변수와 Exam_Score의 관계를 확인한 결과, Hours_Studied와 Previous_Scores는 Exam_Score와 뚜렷한 양의 선형 관계를 보였다. 특히 Previous_Scores는 중앙부에 데이터가 밀집된 구간에서 강한 상관 구조가 관찰되었고, Hours_Studied 역시 학습 시간이 증가할수록 성적이 상승하는 명확한 경향을 나타냈다.

반면 Attendance는 전체적으로는 양의 관계가 보였지만, 특정 점수대에 데이터가 집중되어 있어

선형성을 명확히 파악하는 데 제한이 있었다. 또한 Sleep_Hours, Physical_Activity, Tutoring_Sessions는 분산이 크고 패턴이 일정하지 않아, Exam_Score와의 선형 관계가 시각적으로 뚜렷하게 드러나지 않았다.

4. 모형

가. 예측변수 27개 전체모형 적합


반응 변수(시험 성적)에 대한 회귀 모형을 구축하기 위해 OLS를 사용하여 모든 예측변수 27개로 전체모형을 적합하였다. 모형 적합에는 파이썬 statsmodel.api, statsmodels.stats.outliers_influence를 사용하였다.

OLS Regression Results					
Dep. Variable:	Exam_Score	R-squared:	0.728		
Model:	OLS	Adj. R-squared:	0.727		
Method:	Least Squares	F-statistic:	651.0		
Date:	Sat, 08 Nov 2025	Prob (F-statistic):	0.00		
Time:	01:57:22	Log-Likelihood:	-14051.		
No. Observations:	6607	AIC:	2.816e+04		
Df Residuals:	6579	BIC:	2.835e+04		
Df Model:	27				
Covariance Type: nonrobust					
	coef	std err	t	P> t	[0.025 0.975]
Access_to_Resources_High	1.0024	0.058	17.304	0.000	0.889 1.116
Access_to_Resources_Low	-1.0529	0.067	-15.832	0.000	-1.183 -0.923
Attendance	0.1988	0.002	91.503	0.000	0.195 0.203
Distance_from_Home_Far	-0.3887	0.092	-4.247	0.000	-0.568 -0.209
Distance_from_Home_Near	0.5130	0.056	9.175	0.000	0.403 0.623
Extracurricular_Activities_Yes	0.5577	0.051	10.913	0.000	0.457 0.658
Family_Income_High	0.5857	0.070	8.425	0.000	0.449 0.722
Family_Income_Low	-0.4925	0.056	-8.829	0.000	-0.602 -0.383
Gender_Male	-0.0393	0.051	-0.774	0.439	-0.139 0.060
Hours_Studied	0.2950	0.004	70.506	0.000	0.287 0.303
Internet_Access_Yes	0.9322	0.095	9.828	0.000	0.746 1.118
Learning_Disabilities_Yes	-0.8555	0.082	-10.475	0.000	-1.016 -0.695
Motivation_Level_High	0.5457	0.066	8.240	0.000	0.416 0.676
Motivation_Level_Low	-0.5155	0.058	-8.859	0.000	-0.630 -0.401
Parental_Education_Level_College	0.4816	0.058	8.329	0.000	0.368 0.595
Parental_Education_Level_Postgraduate	0.9780	0.067	14.690	0.000	0.847 1.108
Parental_Involvement_High	1.0561	0.058	18.087	0.000	0.942 1.171
Parental_Involvement_Low	-0.9276	0.066	-14.079	0.000	-1.057 -0.798
Peer_Influence_Negative	-0.5212	0.068	-7.667	0.000	-0.654 -0.388
Peer_Influence_Positive	0.5074	0.056	8.999	0.000	0.397 0.618
Physical_Activity	0.1885	0.024	7.742	0.000	0.141 0.236
Previous_Scores	0.0488	0.002	28.012	0.000	0.045 0.052
School_Type_Private	-0.0313	0.054	-0.574	0.566	-0.138 0.076
Sleep_Hours	-0.0010	0.017	-0.059	0.953	-0.034 0.032
Teacher_Quality_High	0.5483	0.056	9.749	0.000	0.438 0.659
Teacher_Quality_Low	-0.5028	0.086	-5.856	0.000	-0.671 -0.334
Tutoring_Sessions	0.4965	0.020	24.393	0.000	0.457 0.536
const	38.5204	0.308	124.898	0.000	37.916 39.125
Omnibus:	11017.809	Durbin-Watson:	2.008		
Prob(Omnibus):	0.000	Jarque-Bera (JB):	5528074.637		
Skew:	11.550	Prob(JB):	0.00		
Kurtosis:	142.811	Cond. No.	1.40e+03		

VIF	Factor	Features
2	32.258974	Attendance
9	11.306190	Hours_Studied
10	12.119339	Internet_Access_Yes
21	22.850648	Previous_Scores
23	20.078228	Sleep_Hours

해당 모형은 설명력이 0.728로 매우 높아 시험 성적의 변이에 대해 많은 부분을 설명하고 있다

고 볼 수 있다. 하지만 분산확산인자(VIF)가 10을 초과하는 변수가 5개나 존재해 심각한 다중공선성의 문제가 있다.



또한 표준화잔차에 대한 Q-Q plot과 적합값plot을 통해 회귀의 표준 가정을 위배하고 있음이 보이고 이로 인해 회귀계수에 대한 정확도가 떨어져 결과의 신뢰도를 떨어뜨리고 있다. 전체모형은 높은 설명력을 가지고 있지만 표준 가정이 위배되는 정황이 보이며 심각한 다중공선성의 문제가 있기 때문에 이 모형으로 시험 성적에 대해 해석할 수는 없다.

나. 변수선택 후 축소 모형 적합

모든 예측변수를 사용하는 대신 적절한 변수들만 선택하여 모형에 사용하기 위해 전진 선택법, 후진 제거법, 단계적 선택법을 이용하여 모형에 사용할 변수들을 선정하였다. 변수 선택의 기준은 BIC로 변수 개수에 더 강한 패널티를 부여하여 더 간명한 모형이 될 수 있도록 하였다.

[변수 선택 후 모형]

OLS Regression Results				
Dep. Variable:	Exam_Score	R-squared:	0.728	
Model:	OLS	Adj. R-squared:	0.727	
Method:	Least Squares	F-statistic:	732.6	
Date:	Wed, 12 Nov 2025	Prob (F-statistic):	0.00	
Time:	11:22:50	Log-Likelihood:	-14052.	
No. Observations:	6607	AIC:	2.815e+04	
Df Residuals:	6582	BIC:	2.832e+04	
Df Model:	24			
Covariance Type:	nonrobust			
	coef	std err	t	P> t
Attendance	0.1988	0.002	91.532	0.000
Hours_Studied	0.2950	0.004	70.525	0.000
Previous_Scores	0.0488	0.002	28.035	0.000
Tutoring_Sessions	0.4968	0.020	24.411	0.000
Parental_Involvement_High	1.0572	0.058	18.115	0.000
Access_to_Resources_High	1.0016	0.058	17.301	0.000
Access_to_Resources_Low	-1.0530	0.066	-15.839	0.000
Parental_Involvement_Low	-0.9265	0.066	-14.068	0.000
Family_Income_Low	-0.4929	0.056	-8.837	0.000
Peer_Influence_Positive	0.5082	0.056	9.018	0.000
Parental_Education_Level_Postgraduate	0.9771	0.067	14.684	0.000
Motivation_Level_Low	-0.5152	0.058	-8.856	0.000
Teacher_Quality_High	0.5482	0.056	9.749	0.000
Distance_from_Home_Near	0.5132	0.056	9.180	0.000
Extracurricular_Activities_Yes	0.5575	0.051	10.912	0.000
Learning_Disabilities_Yes	-0.8547	0.082	-10.469	0.000
Internet_Access_Yes	0.9317	0.095	9.827	0.000
Motivation_Level_High	0.5458	0.066	8.243	0.000
Family_Income_High	0.5861	0.070	8.432	0.000
Parental_Education_Level_College	0.4820	0.058	8.339	0.000
Physical_Activity	0.1883	0.024	7.733	0.000
Peer_Influence_Negative	-0.5199	0.068	-7.652	0.000
Teacher_Quality_Low	-0.5027	0.086	-5.857	0.000
Distance_from_Home_Far	-0.3881	0.092	-4.241	0.000
const	38.4823	0.280	137.331	0.000
Omnibus:	11019.131	Durbin-Watson:	2.008	
Prob(Omnibus):	0.000	Jarque-Bera (JB):	5531887.674	
Skew:	11.552	Prob(JB):	0.00	
Kurtosis:	142.860	Cond. No.	1.27e+03	

[위의 모형에서 VIF가 10을 초과하는 변수]

VIF Factor	features
2	29.002644 Attendance
8	11.092239 Hours_Studied
9	11.815804 Internet_Access_Yes
20	21.964778 Previous_Scores

해당 결과는 전체모형에서 Gender_Male, Sleep_Hours, School_Type_Private 변수를 제외한 변수들만 선택하여 적합한 것이다. 제외된 변수들은 전체모형에서 p-value가 매우 높게 나온 변수들임을 알 수 있다.

전진 선택을 이용한 모형에서 변수의 수가 27개에서 24개로 축소되었지만 설명력은 줄어들지 않았다. 이는 선택되지 않은 3개의 변수가 시험 성적의 변이에 대해 고유한 설명력을 거의 갖지 않으며 갖고 있다고 하더라도 다른 변수들로 대부

분 설명이 된다는 것이 된다. 또한 간명성의 원칙에 따라 더 적은 변수를 가지는 이 축소모형이 통계적으로 더 효율적이고 우수하다는 것이 된다. 그러나 전체모형에서 VIF가 10을 초과하던 변수들의 VIF 값이 여전히 10을 초과하여 다중공선성의 문제가 변수 선택을 통해 해결되지 않았다는 것을 알 수 있다.

다른 변수 선택 방법인 후진 제거, 단계적 선택을 진행하였으나 전진 선택과 같은 변수들을 선택하였고 그로인해 동일한 결과가 도출되었다. 세 변수 선택 방법으로 전체 모형에서 불필요한 변수들을 제거하는 데에는 성공하였으나 다중공선성의 문제를 해결하는 것은 어려움이 있었다.

다. VIF 10 초과 변수 제거 시도

다중공선성의 문제를 해결하기 위해 앞서 얻은 축소모형에서 VIF가 10을 초과하는 4개의 변수들 중 큰 VIF를 가지는 순서대로 변수를 하나씩 제거해보았다.

[축소모형에서 Attendance만 제거]

OLS Regression Results					
Dep. Variable:	Exam_Score	R-squared:	0.381		
Model:	OLS	Adj. R-squared:	0.379		
Method:	Least Squares	F-statistic:	176.1		
Date:	Mon, 10 Nov 2025	Prob (F-statistic):	0.00		
Time:	12:10:24	Log-Likelihood:	-16764.		
No. Observations:	6607	AIC:	3.358e+04		
Df Residuals:	6583	BIC:	3.374e+04		
Df Model:	23				
Covariance Type:	nonrobust				
		coef	std err	t	P> t
Access_to_Resources_High		0.9856	0.087	11.294	0.000
Access_to_Resources_Low		-0.9851	0.100	-9.831	0.000
Distance_from_Home_Far		-0.4702	0.138	-3.409	0.001
Distance_from_Home_Near		0.5663	0.084	6.721	0.000
Extracurricular_Activities_Yes		0.5507	0.077	7.150	0.000
Family_Income_High		0.6043	0.105	5.768	0.000
Family_Income_Low		-0.4102	0.084	-4.879	0.000
Hours_Studied		0.2915	0.006	46.230	0.000
Internet_Access_Yes		0.7757	0.143	5.428	0.000
Learning_Disabilities_Yes		-1.0157	0.123	-8.255	0.000
Motivation_Level_High		0.4777	0.100	4.786	0.000
Motivation_Level_Low		-0.5436	0.088	-6.199	0.000
Parental_Education_Level_College		0.5203	0.087	5.971	0.000
Parental_Education_Level_Postgraduate		1.1336	0.100	11.305	0.000
Parental_Involvement_High		1.0726	0.088	12.192	0.000
Parental_Involvement_Low		-0.8374	0.099	-8.435	0.000
Peer_Influence_Negative		-0.6421	0.102	-6.270	0.000
Peer_Influence_Positive		0.3719	0.085	4.379	0.000
Physical_Activity		0.1398	0.037	3.809	0.000
Previous_Scores		0.0456	0.003	17.368	0.000
Teacher_Quality_High		0.5742	0.085	6.774	0.000
Teacher_Quality_Low		-0.4393	0.129	-3.395	0.001
Tutoring_Sessions		0.5225	0.031	17.033	0.000
const		54.9182	0.324	169.345	0.000
Omnibus:	5090.300	Durbin-Watson:	1.948		
Prob(Omnibus):	0.000	Jarque-Bera (JB):	202379.321		
Skew:	3.326	Prob(JB):	0.00		
Kurtosis:	29.285	Cond. No.	700.		

	VIF Factor	features
7	10.421202	Hours_Studied
8	10.962046	Internet_Access_Yes
19	18.100369	Previous_Scores

첫번째로 Attendance 변수를 제거하였더니 설명력이 0.382로 감소하였으며 다른 세 변수의 VIF가 소폭 감소하였다. VIF의 감소보다 설명력의 감소가 너무나 크다. 이는 출석이 다른 변수들과 상관관계를 가지고 있지만 출석이 가지는 고유한 설명력 또한 높기 때문에 함부로 제거할 수 없다고 판단된다.

[축소모형에서 Previous_Scores만 제거]

OLS Regression Results				
Dep. Variable:	Exam_Score	R-squared:	0.695	
Model:	OLS	Adj. R-squared:	0.694	
Method:	Least Squares	F-statistic:	652.5	
Date:	Mon, 10 Nov 2025	Prob (F-statistic):	0.00	
Time:	12:09:43	Log-Likelihood:	-14424.	
No. Observations:	6607	AIC:	2.890e+04	
Df Residuals:	6583	BIC:	2.906e+04	
Df Model:	23			
Covariance Type: nonrobust				
	coef	std err	t	P> t
Access_to_Resources_High	1.0090	0.061	16.475	0.000
Access_to_Resources_Low	-1.0973	0.070	-15.607	0.000
Attendance	0.1976	0.002	85.999	0.000
Distance_from_Home_Far	-0.3778	0.097	-3.903	0.000
Distance_from_Home_Near	0.5284	0.059	8.935	0.000
Extracurricular_Activities_Yes	0.5660	0.054	10.471	0.000
Family_Income_High	0.5575	0.074	7.582	0.000
Family_Income_Low	-0.4914	0.059	-8.328	0.000
Hours_Studied	0.2979	0.004	67.352	0.000
Internet_Access_Yes	0.9409	0.100	9.380	0.000
Learning_Disabilities_Yes	-0.8397	0.086	-9.721	0.000
Motivation_Level_High	0.5863	0.070	8.371	0.000
Motivation_Level_Low	-0.4907	0.062	-7.975	0.000
Parental_Education_Level_College	0.4491	0.061	7.344	0.000
Parental_Education_Level_Postgraduate	0.9658	0.070	13.719	0.000
Parental_Involvement_High	1.0480	0.062	16.974	0.000
Parental_Involvement_Low	-0.8956	0.070	-12.855	0.000
Peer_Influence_Negative	-0.5280	0.072	-7.345	0.000
Peer_Influence_Positive	0.4722	0.060	7.922	0.000
Physical_Activity	0.1792	0.026	6.958	0.000
Teacher_Quality_High	0.5755	0.059	9.676	0.000
Teacher_Quality_Low	-0.4337	0.091	-4.778	0.000
Tutoring_Sessions	0.4896	0.022	22.743	0.000
const	42.2071	0.261	161.705	0.000
Omnibus:	10113.230	Durbin-Watson:	2.007	
Prob(Omnibus):	0.000	Jarque-Bera (JB):	3615368.172	
Skew:	9.782	Prob(JB):	0.00	
Kurtosis:	115.916	Cond. No.	836.	

VIF Factor	features
2	23.900016 Attendance
8	10.663108 Hours_Studied
9	11.373046 Internet_Access_Yes

두 번째로 Previous_Scores를 제거하였더니 설명력이 0.695로 소폭 감소하였고, 다른 세 변수들의 VIF값도 소폭 감소하였다. 앞서 Attendance 변수를 제거한 것에 비해 설명력은 조금 줄어들었다. 다른 세 변수의 VIF가 여전히 10을 초과하여 다중공선성의 원인이 되는 변수는 아니지만 해당 변수가 가지는 반응변수에 대한 고유한 설명력이 작기에 모형을 간명하게 만들기 위해서 제거할 수 있는 변수로도 보인다.

[축소모형에서 Internet_Access_Yes만 제거]

OLS Regression Results				
Dep. Variable:	Exam_Score	R-squared:	0.724	
Model:	OLS	Adj. R-squared:	0.723	
Method:	Least Squares	F-statistic:	749.4	
Date:	Mon, 10 Nov 2025	Prob (F-statistic):	0.00	
Time:	12:11:15	Log-Likelihood:	-14100.	
No. Observations:	6607	AIC:	2.825e+04	
Df Residuals:	6583	BIC:	2.841e+04	
Df Model:	23			
Covariance Type: nonrobust				
	coef	std err	t	P> t
Access_to_Resources_High	0.9988	0.058	17.129	0.000
Access_to_Resources_Low	-1.0455	0.067	-15.615	0.000
Attendance	0.1984	0.002	90.714	0.000
Distance_from_Home_Far	-0.3864	0.092	-4.193	0.000
Distance_from_Home_Near	0.5082	0.056	9.027	0.000
Extracurricular_Activities_Yes	0.5547	0.051	10.780	0.000
Family_Income_High	0.5760	0.070	8.229	0.000
Family_Income_Low	-0.5011	0.056	-8.920	0.000
Hours_Studied	0.2951	0.004	70.062	0.000
Learning_Disabilities_Yes	-0.8500	0.082	-10.336	0.000
Motivation_Level_High	0.5489	0.067	8.229	0.000
Motivation_Level_Low	-0.5252	0.059	-8.965	0.000
Parental_Education_Level_College	0.4683	0.058	8.046	0.000
Parental_Education_Level_Postgraduate	0.9780	0.067	14.592	0.000
Parental_Involvement_High	1.0576	0.059	17.991	0.000
Parental_Involvement_Low	-0.9357	0.066	-14.107	0.000
Peer_Influence_Negative	-0.5169	0.068	-7.552	0.000
Peer_Influence_Positive	0.5040	0.057	8.879	0.000
Physical_Activity	0.1850	0.025	7.545	0.000
Previous_Scores	0.0489	0.002	27.868	0.000
Teacher_Quality_High	0.5489	0.057	9.691	0.000
Teacher_Quality_Low	-0.5015	0.086	-5.800	0.000
Tutoring_Sessions	0.4949	0.020	24.147	0.000
const	39.3961	0.266	147.966	0.000
Omnibus:	10875.088	Durbin-Watson:	2.010	
Prob(Omnibus):	0.000	Jarque-Bera (JB):	5175313.795	
Skew:	11.256	Prob(JB):	0.00	
Kurtosis:	138.250	Cond. No.	1.19e+03	

VIF Factor	features
2	26.907038 Attendance
8	10.948843 Hours_Studied
19	21.141720 Previous_Scores

세 번째로 Internet_Access_Yes를 제거하였더니 설명력은 0.724로 거의 변화가 없었고, 다른 세 변수들의 VIF 역시 소폭 감소하였으나 여전히 10을 초과한다. 해당 변수는 제거했지만 설명력의 변화가 거의 없어 이 변수가 가지는 설명력을 다른 변수들로 설명 가능하기에 고유한 설명력을 거의 가지지 않는 것으로 보인다.

[축소모형에서 Hours_Studied만 제거]

OLS Regression Results				
Dep. Variable:	Exam_Score	R-squared:	0.522	
Model:	OLS	Adj. R-squared:	0.520	
Method:	Least Squares	F-statistic:	312.3	
Date:	Mon, 10 Nov 2025	Prob (F-statistic):	0.00	
Time:	12:10:51	Log-Likelihood:	-15911.	
No. Observations:	6607	AIC:	3.187e+04	
Df Residuals:	6583	BIC:	3.203e+04	
Df Model:	23			
Covariance Type: nonrobust				
	coef	std err	t	P> t
Access_to_Resources_High	1.0263	0.077	13.381	0.000
Access_to_Resources_Low	-0.9825	0.088	-11.156	0.000
Attendance	0.1974	0.003	68.602	0.000
Distance_from_Home_Far	-0.3791	0.121	-3.127	0.002
Distance_from_Home_Near	0.4656	0.074	6.287	0.000
Extracurricular_Activities_Yes	0.5319	0.068	7.858	0.000
Family_Income_High	0.5435	0.092	5.902	0.000
Family_Income_Low	-0.5315	0.074	-7.193	0.000
Internet_Access_Yes	0.9606	0.126	7.647	0.000
Learning_Disabilities_Yes	-0.9381	0.108	-8.673	0.000
Motivation_Level_High	0.4386	0.088	5.000	0.000
Motivation_Level_Low	-0.5535	0.077	-7.182	0.000
Parental_Education_Level_College	0.4243	0.077	5.540	0.000
Parental_Education_Level_Postgraduate	0.9494	0.088	10.769	0.000
Parental_Involvement_High	1.0190	0.077	13.179	0.000
Parental_Involvement_Low	-0.8784	0.087	-10.068	0.000
Peer_Influence_Negative	-0.5117	0.090	-5.684	0.000
Peer_Influence_Positive	0.5557	0.075	7.442	0.000
Physical_Activity	0.1967	0.032	6.098	0.000
Previous_Scores	0.0519	0.002	22.509	0.000
Teacher_Quality_High	0.5295	0.075	7.107	0.000
Teacher_Quality_Low	-0.5119	0.114	-4.501	0.000
Tutoring_Sessions	0.4779	0.027	17.725	0.000
const	44.3269	0.355	124.985	0.000
Omnibus:	6642.411	Durbin-Watson:	2.014	
Prob(Omnibus):	0.000	Jarque-Bera (JB):	543095.836	
Skew:	4.824	Prob(JB):	0.00	
Kurtosis:	46.356	Cond. No.	1.20e+03	
VIF Factor	features			
2	27.248099	Attendance		
8	11.663055	Internet_Access_Yes		
19	21.115017	Previous_Scores		



네 번째로 Hours_Studied를 제거하였더니 설명력이 0.522로 감소하였고, 마찬가지로 여전히 다른 세 변수들의 VIF는 10을 초과하고 있다. 설명력의 감소폭으로 보아 Attendance 변수처럼 이 변수가 가지는 고유한 설명력이 커 다른 변수들로 일부 설명되고 있더라도 전체 설명력에서 가지는 비율이 높아 제거하기 어렵다.

[인터넷 접근성과 이전 점수를 제거한 모형]

OLS Regression Results				
Dep. Variable:	Exam_Score	R-squared:	0.691	
Model:	OLS	Adj. R-squared:	0.690	
Method:	Least Squares	F-statistic:	669.3	
Date:	Mon, 10 Nov 2025	Prob (F-statistic):	0.00	
Time:	12:17:54	Log-Likelihood:	-14468.	
No. Observations:	6607	AIC:	2.898e+04	
Df Residuals:	6584	BIC:	2.914e+04	
Df Model:	22			
Covariance Type: nonrobust				
	coef	std err	t	P> t
Access_to_Resources_High	1.0062	0.062	16.322	0.000
Access_to_Resources_Low	-1.0898	0.071	-15.399	0.000
Attendance	0.1972	0.002	85.282	0.000
Distance_from_Home_Far	-0.3761	0.097	-3.860	0.000
Distance_from_Home_Near	0.5235	0.060	8.794	0.000
Extracurricular_Activities_Yes	0.5632	0.054	10.352	0.000
Family_Income_High	0.5473	0.074	7.396	0.000
Family_Income_Low	-0.4997	0.059	-8.414	0.000
Hours_Studied	0.2981	0.004	66.953	0.000
Learning_Disabilities_Yes	-0.8349	0.087	-9.603	0.000
Motivation_Level_High	0.5894	0.071	8.360	0.000
Motivation_Level_Low	-0.5009	0.062	-8.087	0.000
Parental_Education_Level_College	0.4352	0.062	7.073	0.000
Parental_Education_Level_Postgraduate	0.9667	0.071	13.642	0.000
Parental_Involvement_High	1.0484	0.062	16.870	0.000
Parental_Involvement_Low	-0.9048	0.070	-12.904	0.000
Peer_Influence_Negative	-0.5249	0.072	-7.254	0.000
Peer_Influence_Positive	0.4679	0.060	7.798	0.000
Physical_Activity	0.1759	0.026	6.785	0.000
Teacher_Quality_High	0.5762	0.060	9.624	0.000
Teacher_Quality_Low	-0.4323	0.091	-4.731	0.000
Tutoring_Sessions	0.4877	0.022	22.509	0.000
const	43.1344	0.243	177.392	0.000
Omnibus:	9984.865	Durbin-Watson:	2.010	
Prob(Omnibus):	0.000	Jarque-Bera (JB):	3399857.962	
Skew:	9.549	Prob(JB):	0.00	
Kurtosis:	112.477	Cond. No.	767.	
VIF Factor	features			
2	20.208895	Attendance		
8	10.397647	Hours_Studied		

변수 선택을 통해 얻은 축소모형에서 VIF가 10을 초과하는 변수들을 하나씩 제거해 보며 제거 가능해 보이는 변수들을 구별하여 모형을 적합해 보았다. 2개의 변수를 줄이면서 설명력은 0.692로 0.03정도 감소하였다.

4개의 변수를 모두 제거한다면 남게 되는 모든 변수들의 VIF가 10을 초과하지 않지만 설명력의 대부분을 잃게 된다. 그렇기에 많은 고유한 설명력을 가지는 두 변수를 유지했고, 여전히 두 변수들의 VIF는 10을 초과하여 다중공선성의 문제를 가지고 있다. 이를통해 단순히 변수제거를 통해서 다중공선성을 제거할 수 있을지도 모르나 모형 자체의 설명력을 잃게 될 수 있음을 알 수 있다.



데이터 개수: 6607개
 최적의 Alpha (규제 강도): 10.722672
 R-squared (결정계수): 0.7276
 절편 (Intercept): 67.2355

[회귀 계수 (Coefficients)]

Access_to_Resources_High	0.457892
Access_to_Resources_Low	-0.419618
Attendance	2.291547
Distance_from_Home_Far	-0.116257
Distance_from_Home_Near	0.251199
Extracurricular_Activities_Yes	0.273086
Family_Income_High	0.230550
Family_Income_Low	-0.241602
Hours_Studied	1.763987
Internet_Access_Yes	0.245712
Learning_Disabilities_Yes	-0.261912
Motivation_Level_High	0.217828
Motivation_Level_Low	-0.234268
Parental_Education_Level_College	0.220436
Parental_Education_Level_Postgraduate	0.388235
Parental_Involvement_High	0.478426
Parental_Involvement_Low	-0.371712
Peer_Influence_Negative	-0.211031
Peer_Influence_Positive	0.248526
Physical_Activity	0.193671
Previous_Scores	0.702064
Teacher_Quality_High	0.249589
Teacher_Quality_Low	-0.150214
Tutoring_Sessions	0.610264



라. 릿지 회귀로 다중공선성 해결

변수 제거만으로는 다중공선성 문제를 해결할 수 없다고 판단하여, 릿지(Ridge) 회귀를 적용했다. 릿지 회귀는 회귀계수의 크기에 패널티를 부여하여, VIF로 인해 불안정하게 팽창했던 계수들을 안정화시킨다. 이 때, 지정해줘야 하는 패널티의 가도인 람다는 sklearn의 RidgeCV를 사용해 1~100 범위로 적합한 결과, 최적의 alpha(람다) 값으로 약 10.7226이 선택되었다. 또한 릿지는 회귀계수의 크기에 패널티를 부여하기에 각 변수의 스케일일에 영향을 받는다. 이를 StandardScaler을 사용해 스케일링 한 후 적합하였다.

람다가 0이나 1이 아닌 약 10이라는 강도의 페널티가 선택된 것은 다중공선성 문제가 실제로 모형의 예측 성능을 저해하는 요인이었으며 이를 제어하기 위해 유의한 수준의 회귀계수의 축소가 필요했음을 보여준다.

다만, 이 릿지 회귀의 계수를 OLS처럼 해석하는 데는 한계가 있다. OLS의 회귀계수는 다른 예측 변수가 고정일 때 특정 예측변수 1단위 증가로 인한 반응변수의 변화라는 명확한 해석이 가능하다. 하지만 릿지 회귀의 계수는 모형의 안정성을 확보하기 위해 의도적으로 편향시켜 계수가 0에 가깝게 만들었다. 그렇지만 계수 간에 상대적 크기의 차이는 유지되기에 어떤 변수가 다른 변수보다 더 영향력을 갖는지는 판단이 가능하다.

[릿지회귀 모형 정규확률,적합값 플롯]




릿지 회귀가 다중공선성의 문제를 제어했다는 것이 이 모형이 회귀의 표준가정을 만족하게 되었다는 것은 아니다. 릿지 회귀에 대한 표준화 잔차의 정규확률플롯, 적합값 플롯을 보면 여전히 회귀의 표준 가정을 위배하고 있다는 것을 알 수 있다.

마. 표준 가정의 위배 해결 시도

OLS와 릿지 모두 가정의 위배를 확인하기 위한 플롯에서 비슷한 패턴이 관찰되었다. 특히 표준화 잔차에 대한 적합값 플롯에서 대부분의 잔차들은 0의 주위에 분포하는 반면에 일부 소수의 잔차들이 매우 큰 값을 가지고 있다. 이 잔차들에 대한 관측치를 구별하기 위해 변수 선택을 통해 얻었던 OLS 축소모형1에서 Cook's distance를 사용했다. 이때 Cook's distance가 $4/(n-k-2)$ 보다 큰 관측치를 영향점으로 구별하였다.

[Cook's distance 인덱스 플롯]



[해당 관측치들의 기술통계]


count	50.000000
mean	89.200000
std	6.617848
min	78.000000
25%	84.000000
50%	88.500000
75%	94.750000
max	100.000000

위의 결과를 보면 50개의 영향점으로 판단되는 관측치들이 전체 반응변수들의 평균 67점보다 매우 높은 89점을 평균으로 가지면서 78점과 100점 사이에 분포하고 있음을 알 수 있다. 이 영향점을 들이 전체에 대한 평균보다 매우 떨어져 있어 예측과의 차이가 매우 커 잔차 또한 매우 컸던 것으로 보인다. 가정의 위배가 이 고득점 학생 집단이 일반 학생집단과 다른 관계를 가지기 때문이라 판단하고 두 집단을 구별하여 일반 학생 집단만을 가지고 릿지 모형을 적합하였다.

[릿지 모형 2번, 고득점 학생 집단 분리]

최적의 Alpha (규제 강도): 0.284804
R-squared (결정계수): 0.9904
절편 (Intercept): 67.0680

[회귀 계수 (Coefficients)]	
Access_to_Resources_High	0.449546
Access_to_Resources_Low	-0.405824
Attendance	2.308478
Distance_from_Home_Far	-0.148737
Distance_from_Home_Near	0.245127
Extracurricular_Activities_Yes	0.246833
Family_Income_High	0.191531
Family_Income_Low	-0.244331
Hours_Studied	1.785936
Internet_Access_Yes	0.265390
Learning_Disabilities_Yes	-0.307294
Motivation_Level_High	0.200854
Motivation_Level_Low	-0.233397
Parental_Education_Level_College	0.224518
Parental_Education_Level_Postgraduate	0.399593
Parental_Involvement_High	0.454408
Parental_Involvement_Low	-0.395436
Peer_Influence_Negative	-0.203776
Peer_Influence_Positive	0.246789
Physical_Activity	0.242187
Previous_Scores	0.710786
Teacher_Quality_High	0.228493
Teacher_Quality_Low	-0.151254
Tutoring_Sessions	0.614606



두 집단을 구별하게 되면서 Q-Q 플롯은 직선에 가까운 분포를 가지게 되었으며 적합값 플롯도 0의 주위로 무작위하게 분포하고 있다. 이제 회귀

의 가정을 만족하게 되어 해당 모형이 통계적으로 안정적이고 신뢰할 수 있게 되었다.

바. 고득점 집단에 대한 해석

모형의 가정을 만족하게 되었지만 그 과정에서 고득점 학생 집단을 분리했기 때문에 이 집단에 대해서도 따로 분석할 필요가 있다.

변수명	(고득점)-(일반)
Exam_Score	22.131981
Learning_Disabilities_Yes	0.095531
Family_Income_High	0.088601
Extracurricular_Activities_Yes	0.084606
Teacher_Quality_High	0.065811
Motivation_Level_High	0.060824
Parental_Involvement_Low	0.037926
Parental_Involvement_High	0.031453
Access_to_Resources_High	0.021235
Peer_Influence_Positive	0.020885
Parental_Education_Level_College	0.019100
Access_to_Resources_Low	0.001281
Teacher_Quality_Low	0.000564
Gender_Male	-0.017398
Parental_Education_Level_Postgraduate	-0.017651
Family_Income_Low	-0.024606
Internet_Access_Yes	-0.024661
Peer_Influence_Negative	-0.028632
Motivation_Level_Low	-0.033427
Tutoring_Sessions	-0.033976
Distance_from_Home_Near	-0.038292
School_Type_Private	-0.064560
Sleep_Hours	-0.190502
Physical_Activity	-0.330108
Hours_Studied	-0.559564
Attendance	-1.105817
Previous_Scores	-1.501897

위의 표는 두 집단에 대한 각 변수들의 평균 값에 대해 고득점 집단에서 일반 집단 평균을 뺀 값이다. 결과를 보면 고득점 학생 집단이 오히려 Attendance의 평균이 1.1이나 낮고,

Previous_Score는 1.5점 정도 낮다. 더 자세히 살펴보기 위해 몇몇 변수에 대해서 상관계수를 비교하였다.

--- 일반 학생 집단 변수 상관관계 ---

	Exam_Score	Previous_Scores	Hours_Studied	Attendance
Exam_Score	1.000000	0.202725	0.522537	0.676962
Previous_Scores	0.202725	1.000000	0.024281	-0.022807
Hours_Studied	0.522537	0.024281	1.000000	-0.012340
Attendance	0.676962	-0.022807	-0.012340	1.000000

--- 고득점 학생 집단 변수 상관관계 ---

	Exam_Score	Previous_Scores	Hours_Studied	Attendance
Exam_Score	1.000000	0.459222	0.252491	0.560350
Previous_Scores	0.459222	1.000000	0.078986	0.289250
Hours_Studied	0.252491	0.078986	1.000000	0.292261
Attendance	0.560350	0.289250	0.292261	1.000000

일반 학생 집단의 시험 성적과 이전 성적의 상관계수는 0.2027이지만 고득점 학생 집단은 0.4592이다. 다른 공부 시간과 출석 역시 두 집단의 상관계수가 서로 다르다는 것을 알 수 있다. 즉, 두 집단이 서로 다른 패턴을 가지고 있는 다른 집단이다.

5. 해석 및 결론

최종적으로 선택된 회귀 모형에서 회귀계수에 대한 해석을 위해 모형 적합에 사용한 StandardScaler를 이용해 계수를 원래 단위로 변환하였다.

--- 최종 릿지모형의 회귀 계수 ---

Internet_Access_Yes	1.005500
Parental_Education_Level_Postgraduate	1.003429
Parental_Involvement_High	1.002917
Access_to_Resources_High	0.982150
Peer_Influence_Positive	0.503943
Motivation_Level_High	0.502913
Extracurricular_Activities_Yes	0.502904
Teacher_Quality_High	0.501436
Distance_from_Home_Near	0.500012
Tutoring_Sessions	0.499354
Parental_Education_Level_College	0.489520
Family_Income_High	0.486858
Hours_Studied	0.298309
Physical_Activity	0.235069
Attendance	0.199878
Previous_Scores	0.049414
Distance_from_Home_Far	-0.497719
Family_Income_Low	-0.497806
Peer_Influence_Negative	-0.501502
Teacher_Quality_Low	-0.505449
Motivation_Level_Low	-0.512587
Parental_Involvement_Low	-0.984780
Learning_Disabilities_Yes	-1.004665
Access_to_Resources_Low	-1.017011

변환된 회귀계수를 통한 결과와 해석은 다음과 같다. 첫 번째, 가정 환경, 교육 자원에 대한 접근성이 성적에 가장 큰 영향을 미치는 것으로 나타났다. 앞서 CDA에서 성적에 부모의 요인이 긍정적인 영향을 준다고 보았던 것과 일치한다. 또한 Family_Income_Low와 Access_to_Resources_Low의 계수가 음수로서 시험성적을 하락시키는데 영향을 미치고 있다. 이는 부모와 주변 환경이 시험 성적에 유의미한 영향을 미치는 요인임을 보여준다.

두 번째, 학생의 학습 태도와 노력이 시험 성적 향상에 긍정적인 영향을 주었다. Hours_Studied와 Attendance가 양의 부호를 가져 두 변수의 증가가 시험 성적이 향상되는 결과를 보여준다.

세 번째, 다른 변수들에 비해 이전 성적은 시험 성적 향상에 적은 영향을 주었다. Previous_Score의 계수가 약 0.05로 다른 계수들에 비해 작은 값을 가졌다. 이는 이전 성적이 시험 향상에 끼치는 영향보다 학생의 학습 태도나 주변의 환경이 가지는 영향이 더 크다는 것을 보여준다.

마지막으로 분리한 고득점 학생 집단은 일반 학생 집단과 시험 성적 향상에 긍정적인 영향을 주는 요인은 같을 지라도 성적 향상에 미치는 영향의 정도가 달라 두 집단이 서로 다른 패턴, 규칙을 가지기 때문에 구분하여 분석하여야 함을 확인했다.

본 분석은 회귀 모형 적합을 위해 OLS를 사용하며 시작했다. 하지만 전체모형은 다중공선성의 문제와 회귀의 표준 가정이 위배되는 정황을 가져 이를 해결할 필요가 있었다. 변수 선택 절차와 VIF를 확인하며 변수를 조절하기도 하였지만 유의미하게 다중공선성을 제어할 수 없었고 OLS가 아닌 릿지 회귀를 사용하여 다중공선성을 완화하였다. 또한 영향점을 구별한 결과 일반 학생 집단과 고득점 학생 집단이 서로 다른 패턴을 가진 것으로 판단이 되어 두 집단을 구분했다. 이를 통해 처음의 OLS모형에서 다중공선성의 문제와 표준 가정의 위배 문제를 모두 해결하여 통계적으

로 유의하고 신뢰할 수 있는 최종 회귀 모형을 얻을 수 있었다.

[참고문헌]

장상수(2016). 벌어지는 틈새: 부모의 사회경제적 지위가 자녀 성적에 미치는 영향의 증가. 한국사회학, 50(5), 107-140

신문승(2018). 초등학교 융합인재교육(STEAM)프로그램의 효과 메타분석. 통합교육과정연구, 12(2), 47-66

박영신, 김의철(2003). 한국 학생의 자기효능감, 성취동기와 학업성취: 토착심리학 접근. 교육심리연구, 17(1), 37-54